从零看懂我们的 Final Project

大学生退学预警：能预测多准，哪些学生容易被漏掉?

这份讲义写给还不会 R、模型和公平性指标的组员。目标是让你能用自己的话解释：我们研究什么、每个数字怎么算、图表说明什么，以及证据还不能证明什么。

先理解，再练习讲。 不需要第一遍就掌握所有代码。先读第1、4-5、10、14、19、21-26、34-35节，抓住项目主线；再读其余小节补上理由和代码。

你现在想解决的问题	先看哪里
完全不知道项目在干什么	第1-7节
不懂模型、概率和0.31	第10-13节
看不懂187、222、98、382	第14-19节
分不清三个公平性标准	第21-26节
不懂区间、bootstrap和校准	第27-30节
不会讲PPT、不知道怎么分工	第34-39节
想在RStudio里找到代码	第32-33节

全文41页：本页是阅读说明，后面40节各占一页。标题编号是小节号，例如第14节在PDF第15页；PDF书签可直接跳转。展示前8页是主讲，第9页是来源，第10-18页是答辩备用页。

本讲义依据当前项目代码、保存的R结果、真实图表和来源材料编写。这里的讲解不代表小组已经掌握、排练或获得选题批准。标为“教学示例”的数字只帮助理解，不是新研究结果。

阅读顺序可以反复： 看一句结论，找数字证据，再关上讲义用自己的话复述。能复述并能回答“分母是谁”，比背出整段英文更有用。

01 | 先用一个故事理解整个项目

想象一所大学希望在新生入学时安排支持。它不能等到学生离开以后才说“我早就知道”。因此，我们只考虑入学时可以获得的信息，看看能否提前识别后来被记录为Dropout的学生。

这里有两个不同的问题。第一，模型能找到多少条后来的退学记录？第二，即使总体表现还可以，它会不会更容易漏掉某些群体？

我们实际做的事情

1. 用一个葡萄牙高校的历史数据，明确“退学记录”是什么意思。

2. 只选入学年龄、入学成绩和专业，训练一个模型。

3. 模型给每名测试学生一个分数，再按0.31这条共同规则决定是否预警。

4. 把预警和实际记录对照，统计找到、漏掉、误报和正确不报的人数。

5. 分别检查Female和Male记录，比较不同分母下的错误比例。

最重要的一组结果

在889名测试学生中，有285名被记录为Dropout。我们的规则找到187名，漏掉98名；另有222名没有该退学记录的学生也被预警。

Female组实际退学记录中的漏报率为44.4%，Male组为24.1%。同一个规则产生了不同的错误分布。

可以讲出的结论： 入学信息有一定预测信号，但误报、漏报和群体差异都很明显，需要进一步验证和人工审阅。

不能讲出的结论： 我们已经证明这个系统能减少退学，或者已经证明某个人一定需要或不需要支持。数据没有告诉我们这些。

02 | 先认清“数据、变量、模型、结果”

把数据表想成Excel：一行是一条学生记录，一列是这个记录的一个属性。年龄这一列放年龄，专业这一列放专业，Target这一列放后来记录的结局。

英文	在本项目中的意思	例子
Observation / record	一条被分析的记录	一行学生资料
Variable / feature	描述学生的一列信息	年龄、入学成绩、专业
Outcome / target	想预测的实际记录	是否被记为Dropout
Model	从训练资料学习出的计算规则	Logistic regression
Probability / score	模型输出的0到1分数	教学示例：0.40
Threshold	把分数变成预警的分界线	本项目0.31
Prediction / warning	模型的判断	预警或不预警
Evaluation	用实际记录检查判断	比较TP、FP、FN、TN

最容易混淆的是哪两个东西?

实际结局Y来自原始数据；**预警R**来自模型。因为两者来源不同，才可能出现错误。若你把实际Target直接当成模型输入，就等于把答案交给模型了。

模型分数、预警和实际结局也不是同一回事。0.40是一个分数；在0.31阈值下会被预警；这个学生最终仍可能没有退学记录。

小检查： 如果模型预警，但原始Target是Graduate，这就是一次“预警与记录不一致”。不要因为预警就把Target改成Dropout。

03 | 数据从哪里来，代表谁?

数据来自UCI Machine Learning Repository，编号697：Predict Students' Dropout and Academic Success。原始研究描述的是葡萄牙Portalegre理工学院的行政资料。

我们实际核对的内容	结果与含义
学生记录	4,424条
来源	一所葡萄牙高校，17个本科专业
入学年份范围	2008/09至2018/19
下载文件结构	36列候选输入信息，加1列Target，共37列
授权	CC BY 4.0；使用时保留来源署名
原文与下载文件的区别	论文写35个属性；当前下载文件核对为36个候选输入，按实际文件分析

为什么“公开数据”还需要解释?

公开只说明我们能够获取这些记录，不说明它能代表所有大学、所有国家或现在的爱丁堡学生。招生制度、专业设置、费用和支持方式都可能不同。

我们拿到的是历史记录，不是现场试验。数据没有让我们随机给学生分配支持措施，所以无法从这里证明某种支持“造成”了退学减少。

展示时怎样说清楚?

“We used 4,424 records from one Portuguese institution.” 这句话先限定来源。之后再说预测与错误，就不会让听众误以为我们研究的是爱丁堡全体学生。

参考：Realinho等，UCI DOI 10.24432/C5MC89；原始数据说明论文Data 2022, 7, 146，第1-4页。完整网址放在本讲义末页。

04 | 三种原始标签怎样变成研究问题?

原始Target有三个类别。我们没有把仍在读的学生偷偷当成毕业生，也没有在主分析里删除他们。

原始标签	人数	原意	主分析Y
Graduate	2,209	在记录终点为毕业	0
Enrolled	794	在记录终点仍在读	0
Dropout	1,421	在记录终点被记为退学	1

Y=1表示“被记录为Dropout”。Y=0表示“在这个终点没有该退学记录”。这里的0不等于“已毕业”，更不等于“永远不会退学”。

为什么可以合成0和1?

因为我们的主问题是“能否识别这个观察终点的退学记录”，不是分别预测毕业、仍在读和退学三种结局。二分类是对研究问题的选择，原来的三个标签仍保留用于解释和敏感性检查。

这项选择有代价：Enrolled学生还没有最终毕业结局，把他们归在0里会使预测含义依赖这个观察终点。因此展示中必须说明终点，备用页还检查了排除Enrolled后结果怎样变化。

代码的意思

```
dropout = as.integer(Target == "Dropout")
```

==先判断是否相等，得到TRUE或FALSE；as.integer()把TRUE变为1、FALSE变为0。这不是把原始Target重写成毕业，而是另外建立一个二分类结果列。

05 | “入学预警”到底预测什么时候?

预测时点：入学时。观察终点：专业的正常学制结束时。 原始论文说明多数专业为3年，护理为4年。它不是“下个月会不会退学”，也不是“第一学期会不会退学”。

原始定义还把换专业或转到其他高校记为Dropout。因此这里的退学记录，比“永远离开高等教育”更宽泛。

一个教学示例

一名学生入学，后来转到另一所大学继续读书。原始数据可能仍将这条记录归为Dropout。模型若把他识别出来，是识别到了这个行政定义，不能据此说他学习失败或一定需要干预。

为什么这会改变我们的结论?

标签定义决定模型在学习什么。它学习的是与记录相符的模式，不能自动理解学生离开的原因、个人意愿或真实支持需求。

数据没有每个学生的离开日期，也没有可以直接用于按时间切分的入学年份字段。虽然论文给出总体年份范围，我们仍不能假装已经做了“用早年训练、晚年测试”的验证。

你需要能讲出的三句话

1. 我们预测的是正常学制终点的行政退学记录。

2. 这个标签包含一些转学或换专业情况。

3. 识别记录不等于识别谁一定需要帮助，更不等于证明干预有效。

对应展示第2页。 讲清楚这一步，是后面所有模型结果成立的前提。

06 | 为什么不能把所有列都放进模型?

如果研究“入学时预警”，模型只能使用当时已经能知道的信息。第一、第二学期成绩是在以后产生的，不能拿它们假装做入学预测。这叫预测时间上的data leakage，数据泄漏。

信息	主分析怎么处理	原因
入学年龄	使用	与入学时点匹配
入学成绩	使用	是入学已有信息，尺度0-200
专业Course	使用	入学专业类别
记录性别Gender	分组审计；额外模型才使用	用来检查群体错误，主模型不使用
日间/夜间就读	不加入主模型	训练数据中由专业完全决定，信息重复
第一、第二学期成绩	排除	入学时还没有发生
欠费、缴费状态、奖学金	保守排除	个体记录时间不明确
宏观经济指标	排除	简化主模型，且缺个人年份核对

一个直观类比

你想在开学前预测期末表现，却把期末成绩交给模型。结果可能很好，但开学前根本无法获得那一列，因此不能完成原来的任务。

排除某列不等于它没用。例如学期成绩可用于“第一学期结束后的预警”，但那是另一个预测时点，需要重新设计问题和验证。

要记住的选择理由： 我们优先保证信息可用时间清楚，而不是尽量把结果做得好看。

07 | 数据检查和数字编码怎么理解?

当前R检查发现：4,424行，37列，没有NA单元格，没有完全相同的整行重复，年龄范围17-70岁。没有NA不代表所有信息都完整可靠。

“未知”可能写成数字

例如父母学历中的34表示Unknown。这样的格子不是NA，但含义仍是未知。父母职业中的90/99也要按字典解释，不能直接视为普通职业或一律删掉。本模型没有选择这些变量，仍记录了这项限制。

为什么Course要变成factor?

专业编号是名称的编码，不是数量。例如代码更大不表示“专业更多”，也不表示专业之间相差几千个单位。如果把编号当连续数字，模型就会强加不合理的大小和距离关系。

```
course = factor(as.character(Course))
```

as.character()把编码作为文字标签；factor()告诉R：这是不同类别。模型可以给不同专业不同的基准水平。

为什么记录性别只显示两组?

原始文件只有0和1，对应Female和Male。我们报告的是这两个记录类别，不是完整的性别身份分类，也不能声称已经评估所有学生群体的公平性。

小检查： “没有NA，所以数据没有任何偏差”对吗？不对。定义、编码、未记录的信息和来源代表性仍可能有问题。

08 | 先补上看图需要的统计基础

Mean平均数： 所有数加起来再除以人数。**Median中位数：** 把数排序后的中间位置。很大的个别数容易拉动平均数，中位数通常较稳。

SD标准差： 表示个体数值的离散程度，和原变量同单位。**IQR四分位距：** Q3-Q1，是中间50%数值覆盖的宽度。这些都不是模型准确率。

箱线图Boxplot怎么读?

1. 箱子中间的线是中位数，不是平均数。

2. 箱子下边是Q1，上边是Q3，中间约50%的记录在箱体范围内。

3. 在本项目的ggplot默认规则中，须延伸到距箱体不超过1.5×IQR范围内最远的观测值。

4. 须外面的点是按此规则单独画出的观测，不是自动判定的错误数据。

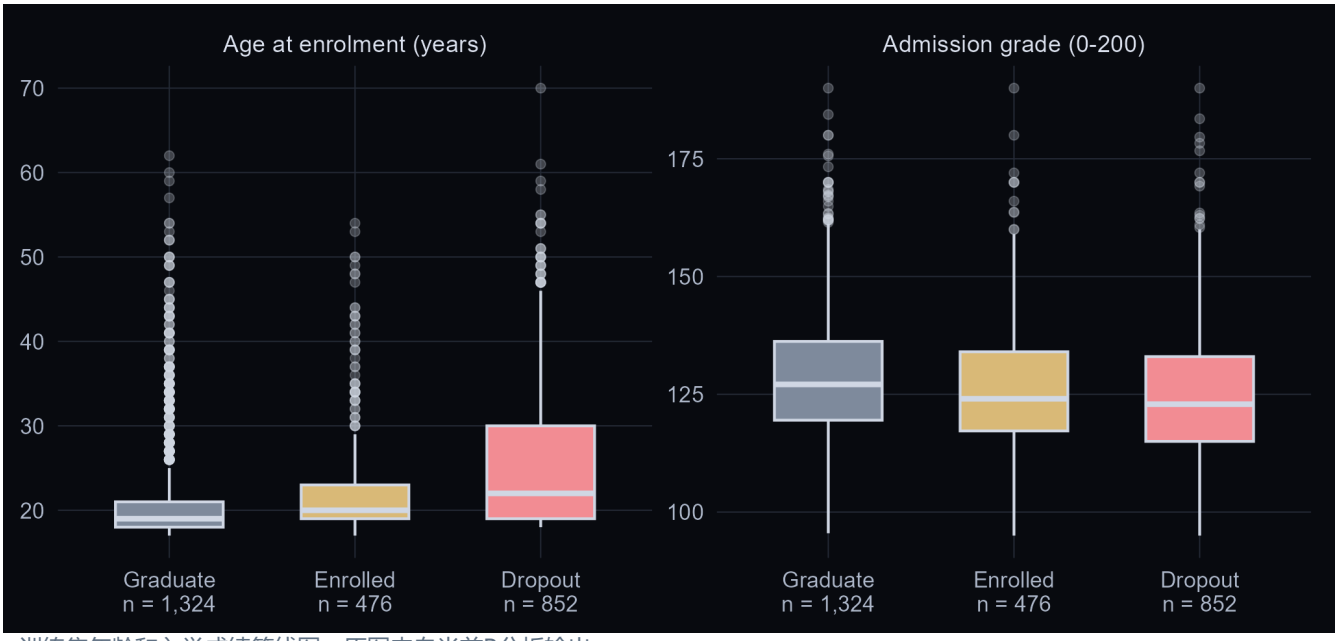
两个经常被误读的地方

箱子通常不是置信区间，箱子窄也不代表模型更准确。默认等宽箱体本身也不能表示各组有多少人，所以我们在类别下面补上n。

两组箱体重叠，说明只看这个变量很难把每个人完全分开；即便中位数不同，也不能说组内每个人都符合这种趋势。

一句练习： “退学记录组的年龄较高，但与其他组有重叠，所以年龄有群体关联，不决定个人结局。”

09 | 把第3页的真实图看懂



训练集年龄和入学成绩箱线图。原图来自当前R分析输出。

训练组别	n	年龄中位数	入学成绩中位数
Graduate	1,324	19岁	127.10
Enrolled	476	20岁	124.05
Dropout	852	22岁	122.90

左面板看年龄，右面板看入学成绩，单位和纵轴尺度不同。不能拿左边箱子的像素高度和右边比大小。

退学记录组的年龄中位数更高，年龄分布也较宽。入学成绩的中位数略低，但各组有大量重叠。这支持“存在关联”，不支持“仅看成绩就能准确判断所有人”。

这张图只用训练集2,652条记录，避免看过测试结果后再挑变量。Data to Viz的箱线图建议促使我们标注各组人数；保留箱线图是为了比较中心与分散程度。

10 | 为什么分训练、验证、测试三份?

可以把它理解成“学习规则、选择用法、最后检查”三个不同工作。下面只是学习类比；实际分析按学生记录划分。

数据部分	人数	负责什么	不该负责什么
Training训练集	2,652	估计模型里的参数；看初步分布	假装是全新表现
Validation验证集	883	选择共同阈值	当作最后无偏的成绩单
Test测试集	889	检查已经固定的模型和阈值	反复帮我们挑最好看的方案

为什么不在同一批资料上学习并打分？模型可能只是适应了已有资料中的偶然特征，这叫overfitting，过拟合。对训练资料的好表现不一定延续到新记录。

项目大约按60/20/20划分，并在原始结局和记录性别组合内随机分配，尽量保持组成相近。人数受各层取整影响，并不是精确60%、20%、20%。

seed是做什么的?

set.seed(20261105)让相同环境中的随机划分可以重现。它不是给模型加分，也不能让某次划分自动更有代表性。

用结局进行分层划分本身不等于把测试答案交给模型；关键是最终模型拟合、特征选择和阈值选择没有使用测试表现。

这里没有按年份留出未来学生，因此测试结果仍是同一来源历史数据中的随机留出表现，不能称为未来部署验证。

11 | 模型到底是一个什么东西?

我们的主模型是**Logistic regression，逻辑回归。**虽然名字有regression，它在这里用于预测一个二分类结果：Y=1或Y=0。

模型用训练资料学习年龄、成绩和专业与记录结局之间的模式，给新资料计算0到1之间的分数。这个分数用于排序风险和决定是否预警。

先不用公式理解

教学示例：两名学生得到0.40和0.20。模型把前者排得更高。0.40不表示“这个人40%已经退学”，也不表示模型对这次判断有40%信心；它是模型对所定义结局的概率估计，可靠程度要另行检查。

想看公式时再读这一段

先算一个加权分数z，再把z转成0到1之间的p：

z = b0 + b_age × age10 + b_grade × admission10 + 专业对应的项

p = 1 / (1 + exp(-z))

这里b是从训练集估计的参数。Course是类别，所以不同专业有不同项，而不是直接乘上原来的专业编号。

模型假设年龄与成绩对log-odds的作用是线性相加的，且没有在主模型中加入交互项。现实可能更复杂，模型也可能漏掉影响结局的重要信息。

你不需要先会推导这个公式。 先能解释“输入三类入学信息，输出一个概率估计；再用共同阈值变成预警”就抓住了主线。

12 | 把核心建模代码逐行翻译

下面是实际分析中的核心语句，省略了周围保存文件和额外检查。代码不是另一种模型。

```
primary_formula <- dropout ~ age10 + admission10 + course
primary <- glm(primary_formula,
               data = training, family = binomial())
validation$probability <- predict(
  primary, newdata = validation, type = "response")
```

代码	应该怎样理解
<-	把右边结果保存到左边的名字
dropout ~ ...	想用右边变量解释、预测左边结果
公式里的+	加入另一个预测变量；不是拼接数据表
glm()	拟合广义线性模型的R函数
data = training	只使用训练资料拟合
family = binomial()	对二分类结果用二项分布模型，默认logit连接
predict()	用已经拟合的模型对指定资料算预测
type = "response"	输出概率尺度，不输出log-odds
$probability	表中的probability这一列

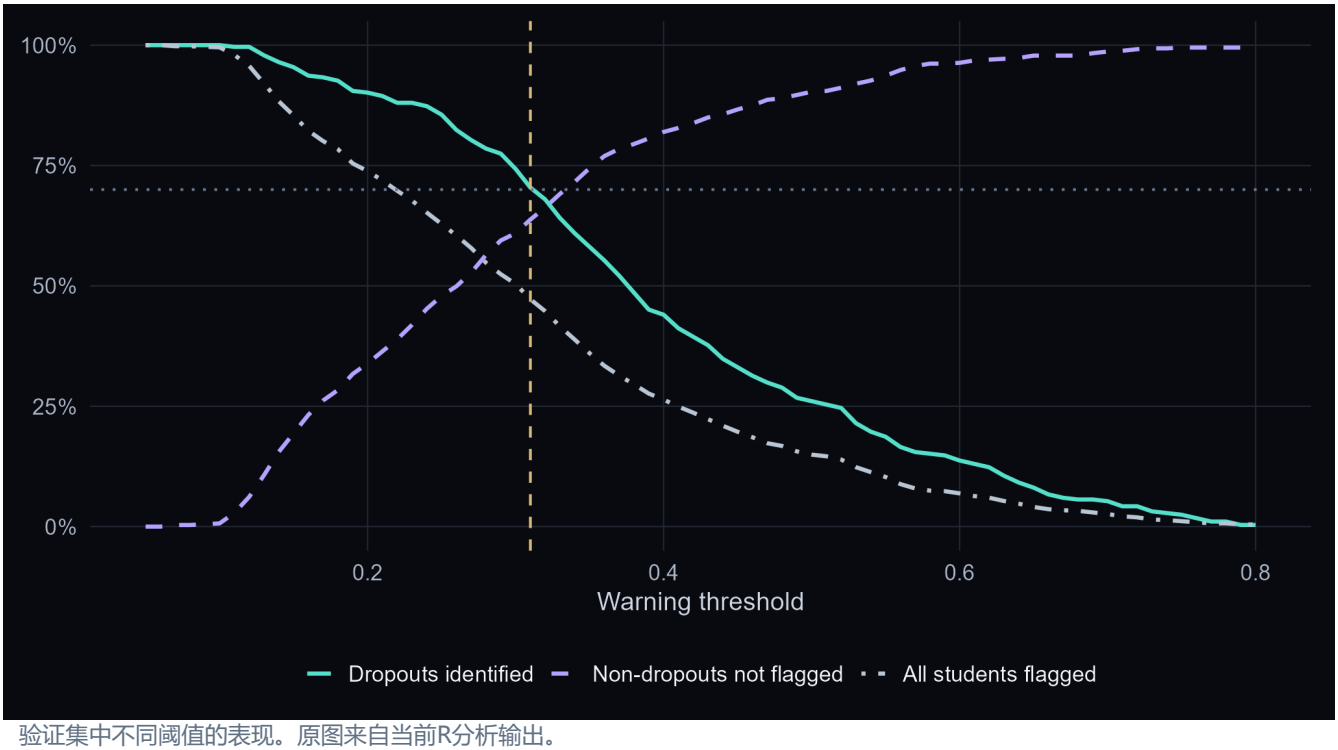
age10=age/10，admission10=admission_grade/10只是换了单位。20岁写成2，130分写成13。模型参数会随尺度改变；这种重新表达本身没有增加新信息。

主模型没有Gender。额外模型才加入Gender作比较，但我们没有因为测试结果稍好就用它替换预先固定的主模型。

13 | 为什么阈值是0.31，不是0.50?

分数和预警之间还差一条规则。本项目用：**分数大于或等于0.31，就预警。** 恰好0.31也属于预警。

教学示例：分数0.40在0.31规则下预警，在0.50规则下不预警。分数并没有变化，变化的是决定。



验证集中不同阈值的表现。原图来自当前R分析输出。

图的横轴是阈值；纵轴是验证集上的比例。降低阈值通常会让更多人被预警，找到更多退学记录，也产生更多误报。

实际选择：在0.05到0.80、每次增加0.01的候选值中，先保留验证集Sensitivity至少70%的阈值，再选Specificity最高的；若同值则按阈值降序。选出0.31，验证集识别200/284，约70.4%。

70%是我们的示例性分析目标，不是老师规定、大学政策或已证实的最佳标准。 真实使用还要讨论支持名额、漏报和误报的代价。阈值只在验证集选择；测试集没有负责选择它。

14 | 先把四格表彻底看懂

这张confusion matrix把889名测试学生全部放进四格。列看实际记录，行看模型是否预警。四个字母可以暂时放一边，先看中文。

	实际Dropout：285人	无该退学记录：604人	行合计
预警	TP=187：找到	FP=222：误报	409
不预警	FN=98：漏掉	TN=382：正确不报	480
列合计	285	604	889

Positive在这里指“预警为退学”，不是“好消息”。**Negative**指“不预警”。True和False则说明这次判断与记录是否一致。

缩写	展开	在项目里发生了什么
TP	True Positive	预警，且实际有退学记录
FP	False Positive	预警，但没有该退学记录
FN	False Negative	不预警，但实际有退学记录
TN	True Negative	不预警，也没有该退学记录

核算：187+222+98+382=889；187+98=285；222+382=604；187+222=409。任何比例都应该能回到这些数。

“误报”只是相对于这个行政标签的预测错误。没有退学记录，不代表学生完全不需要帮助。

先试一题： 想问“实际退学记录里漏掉多少”，分母用285，不是889，也不是409。

15 | 为什么不能只看Accuracy?

Accuracy，准确率，问的是全部测试学生中有多少次判断与记录一致：

Accuracy = (TP + TN) / 全部人数 = (187 + 382) / 889 = 64.0%

但不发任何预警，也能把所有604名没有退学记录的人判对。这个“Always no warning”基准的准确率为604/889=67.9%，比64.0%还高，却找不到任何退学记录。

规则	找到退学记录	漏掉退学记录	Accuracy
全部不预警	0/285	285/285	67.9%
模型阈值0.50	80/285	205/285	71.9%
模型阈值0.31	187/285	98/285	64.0%

这是不是说明模型没用?

不能只凭这一项决定。若目的是找到可能需要进一步对话的学生，漏掉285人和漏掉98人的后果不同；但多预警也消耗资源。我们要同时比较两种错误，而不是挑一个最高指标。

当前数据中没有退学记录的人更多，这是类别不平衡的一种表现。多数类容易让“全部猜多数类”的准确率看起来不低。

答辩可说： “Accuracy alone would reward a rule that never warns anyone. We also report missed records and false warnings.”

这里没有证明0.31的实际社会效益一定高于0.50。若没有支持成本和干预效果数据，最终用途判断仍有限。

16 | Sensitivity和FNR：先只看实际退学的人

先把没有退学记录的604人移出视野，只看285名实际被记为Dropout的测试学生。其中187人被找到，98人被漏掉。

问题	公式	结果
实际退学记录中找到多少?	Sensitivity = TP/(TP+FN)	187/285=65.6%
实际退学记录中漏掉多少?	FNR = FN/(TP+FN)	98/285=34.4%

Sensitivity也叫Recall或True Positive Rate，TPR。FNR是False Negative Rate，漏报率。两项分母相同，且Sensitivity+FNR=100%。

用100人理解

把65.6%理解成：在这批测试资料中，每100名有退学记录的学生，规则大约找到66名、漏掉34名。这是把真实比例缩放后的解释，不是另一次调查。

为什么不能说“系统保证识别70%”？

70%是验证集上的选择目标；验证实际70.4%，测试只有65.6%。不同资料上的表现会变化。测试的95%条件bootstrap区间约60.3%-71.0%，也没有保证未来人群达到70%。

常见误读： 把Sensitivity说成“预警的人中有65.6%真的退学”。这换了分母；预警者中的真实退学比例是PPV，见第18节。

自问： FN变大、TP不变时，漏报率会上升还是下降？会上升，因为真实退学记录中被漏掉的份额更大。

17 | FPR和Specificity：只看没有退学记录的人

现在只看604名在终点没有Dropout记录的测试学生。其中222人仍被预警，382人没有被预警。

问题	公式	结果
无退学记录的人中误报多少?	FPR = FP/(FP+TN)	222/604=36.8%
无退学记录的人中正确不报多少?	Specificity = TN/(FP+TN)	382/604=63.2%

FPR是False Positive Rate，误报率；Specificity是特异度，也叫True Negative Rate，TNR。两项相加为100%。

两种“误报比例”不是同一个数

222/604问：没有退学记录的人中，多少被错误预警？这是FPR。

222/409问：所有预警中，多少不符合退学标签？这是1-PPV，约54.3%。它们分子相同，但分母不同，不能都简称为同一个误报率。

对学生支持意味着什么?

若每个预警都安排人工联系，FPR涉及会联系多少没有该标签的人。不过这些人也可能有支持需求；现有标签只记录结局，没有测量他们是否需要帮助。

阈值降到0.31后，测试误报率由阈值0.50时的45/604=7.5%升至36.8%。这与找到更多退学记录一起，构成需要解释的取舍。

记忆方法： 看到FPR，先说“实际没有退学记录的人里面”；看到FNR，先说“实际有退学记录的人里面”。

18 | PPV、NPV和FOR：这次先看模型说了什么

前两页先按实际记录分组；这一页先按是否预警分组。这是为什么分母会改变。

先看哪群人	想知道什么	计算
409名被预警者	多少有退学记录？PPV	187/409=45.7%
480名未预警者	多少无退学记录？NPV	382/480=79.6%
480名未预警者	多少仍有退学记录？FOR	98/480=20.4%

PPV也叫Precision，阳性预测值。NPV是阴性预测值。FOR是False Omission Rate，等于1-NPV。NPV和FOR在未预警这群人内部相加为100%。

FNR和FOR为什么不一样?

同样是98名漏掉的人：FNR=98/285，问所有实际退学记录中漏掉的份额；FOR=98/480，问所有没预警的人中仍有退学记录的份额。

PPV和Sensitivity为什么也不一样?

同样是187名找到的人：PPV除以409名预警者；Sensitivity除以285名实际退学者。一个从模型决定出发，一个从实际结局出发。

读比例前，先完整说出条件。 例如“在所有被预警的学生中，45.7%有该退学记录”，比“模型45.7%准确”清楚得多。

最后，409/889=46.0%是Warning rate，预警覆盖比例。它既不是PPV，也不是Sensitivity；它反映需要处理多少预警。

19 | 第6页的核心发现：多找到，也多误报

比较的是**同一个模型**在两个阈值下的决定。概率排序不变，分类规则变了。

测试结果	阈值0.50	验证选定0.31	变化
找到退学记录TP	80	187	多107人
漏掉FN	205	98	少107人
无该记录却预警FP	45	222	多177人
全部预警人数	125	409	多284人
Sensitivity	28.1%	65.6%	上升37.5个百分点
PPV	64.0%	45.7%	下降18.3个百分点

为什么找到更多，PPV反而下降？因为新增预警中既有真正的退学记录，也有很多没有该记录的人。预警数量增长得更快，所以预警里的命中比例下降。

怎样自然解释?

“降低阈值后，我们找到的退学记录从80增加到187，但误报也从45增加到222。所以不能只展示‘多找到107人’，还要告诉听众新增了177次误报。”

为什么要说“个百分点”？

从28.1%到65.6%相差37.5个百分点。它不是相对增加37.5%；相对变化要另除以原来的28.1%。讲义和展示谈比例差时使用percentage points，pp。

结论要包含资源问题：若联系409名学生，学校有没有能力跟进？当前分析没有提供这个答案。

20 | AUC和Brier：概率本身还要怎样检查?

阈值决定某一次预警，但模型还输出概率分数。AUC和Brier从不同角度检查分数，都是补充指标。

AUC：能否把退学记录排得更高?

本项目主模型测试AUC约0.718。直观上，随机取一名有退学记录者和一名无该记录者，模型把前者排得更高的比例约71.8%；并列按一半计。0.5相当于没有排序区分，1表示这批资料完全排序正确。

AUC=0.718不是“71.8%的学生判断正确”。 它也不保证概率可靠，不代表学校有资源处理预警。阈值从0.50改到0.31，模型分数不变，所以AUC也不变。

Brier score：概率离0或1结局有多远?

Brier = mean((p - y)^2)，越小表示平均概率平方误差越低。主模型约0.188，基准约0.218。

教学示例：实际y=1，预测p=0.8，误差为(0.8-1)^2=0.04；预测0.2，误差为0.64。Brier使用所有人的概率，不只看过没过阈值。

基准在分类时全部不预警，但它的概率列使用训练集退学比例，而不是全部设成0。因此其Brier不能直接用“全部概率0”的结果代替。

展示主要讲错误和支持含义；AUC、Brier和公式适合答辩备用。它们不是公平性证明，也不能单独决定是否部署。

21 | 公平性分析先固定哪些东西?

公平性不是“分成两组，哪组数字更高就说偏见”。先固定研究的正类、模型、阈值、群体和比例的分母。

符号或约定	本项目里的意思
Y=1	实际记录为Dropout
Y=0	在终点无该退学记录，包含Graduate和Enrolled
R=1	模型分数至少0.31，被预警
R=0	模型分数低于0.31，没有预警
A	数据中的记录性别类别，Female或Male
p	连续概率分数，和二分类R不同

两组使用同一个已经固定的主模型和同一个阈值。下面所有主结果都来自同一批889名测试学生。

组别	总数	TP	FP	FN	TN
Female	575	80	138	64	293
Male	314	107	84	34	89
合计	889	187	222	98	382

三个标准各问一件事：**Independence先看全部人；Separation先看实际结局；Sufficiency先看模型决定。** 下一页开始逐个算。

当我们说“检查某标准”，指的是报告与该标准有关的实际比例和不确定性。有限样本里接近或不同，都不等于已经证明整个系统公平或歧视。

22 | Independence：谁更常收到预警?

Independence在这里问：不先区分实际是否退学，两个记录性别组获得预警的比例是否相同？也常称demographic parity，人口统计均等。

组别	预警人数TP+FP	这一组全部人数	预警率
Female	80+138=218	575	218/575=37.9%
Male	107+84=191	314	191/314=60.8%

Female组预警人数218比Male组191还多，但Female组本来就大得多。比较覆盖比例时，应比较37.9%与60.8%，不能只比218和191。

符号看不懂时怎样翻译?

P(R=1 | A=Female)读成： “在Female组这个条件下，收到预警的比例。” 竖线|就是“在……条件下”。

Independence要求模型决定R的分布不依赖群体A。对于二分类R，只需比较R=1的比例，因为R=0的比例是它的补数。

它和学生支持怎样关联?

若预警触发联系，覆盖率不同意味着两组被联系的份额不同。但单看这一行，不能知道谁更容易漏掉，也不能知道预警是否可靠。那分别是后面的Separation和Sufficiency。

可以说： 本测试集的预警率存在明显差别。**还不能说：** 只要把两组都调成同样预警率，所有公平问题就自动解决。

23 | Separation：相同实际结局，错误是否相近?

Separation先按Y分开，再比较两组的预警情况。实际退学者看漏报，实际未退学者看误报。二分类下，两层都要检查。

条件	Female	Male	在比较什么
Y=1：实际Dropout	144人	141人	真实退学记录的规模
其中漏掉FN	64人	34人	FNR=44.4%对24.1%
Y=0：无该记录	431人	173人	非退学记录的规模
其中误报FP	138人	84人	FPR=32.0%对48.6%

漏报比较： 64/(80+64)=64/144=44.4%；34/(107+34)=34/141=24.1%。不是除以575或314。

误报比较： 138/(138+293)=138/431=32.0%；84/(84+89)=84/173=48.6%。

为什么这比看总人数更重要?

两组实际退学记录数量相近，Female却漏掉64名、Male漏掉34名。这对应标题里的“哪些学生容易被漏掉”。另一方面Male在无该记录者中误报比例更高。

主展示用FNR和FPR表达；比较TPR和FPR也是同一类Separation检查，因为TPR=1-FNR。只看TPR相同通常只检查equal opportunity的一层，不是完整Separation。

准确结论： 本测试集两组错误率不同，值得调查。原因可能涉及专业构成、未观测因素、标签与模型假设，不能从这一张表直接断定原因或歧视。

24 | Sufficiency：收到同样判断，含义是否相近?

Sufficiency换一个观察方向：先按模型说的R分开，再问两组实际结局Y是否相近。既看预警者，也看没有预警者。

固定模型决定	Female	Male
R=1：预警人数	218	191
预警者中实际Dropout，PPV	80/218=36.7%	107/191=56.0%
R=0：未预警人数	357	123
未预警者中实际Dropout，FOR	64/357=17.9%	34/123=27.6%

第一层说明：同样收到预警，在这批资料里，Female的预警与Dropout标签匹配的比例较低。
第二层说明：同样未收到预警，Male记录中仍为Dropout的比例较高。

为什么只检查PPV还不够?

PPV只涉及R=1。完整的二分类Sufficiency还涉及R=0；可以比较FOR，也可以比较NPV，因为两者互补。当前两层都保留。

它和Separation怎么区分?

FNR是$P(R=0 \mid Y=1,A)$，先锁定真实退学者。FOR是$P(Y=1 \mid R=0,A)$，先锁定没预警的人。两个条件顺序不同，不能互换。

这些差别说明“相同预警标签”的实际含义并不完全相同。它们是对有限测试记录的描述，不等于已经完成可推广到所有学生的公平性认证。

25 | 五行指标放在一起，先读分母

下面就是第7页主图与第10页备用表的读法。每一行只比较同一个问题下的两组，不能把不同行百分比随意当成同一件事。

标准与问题	Female	Male
Independence：全部人里多少被预警?	218/575=37.9%	191/314=60.8%
Separation：无退学记录中多少误报?	138/431=32.0%	84/173=48.6%
Separation：有退学记录中多少漏掉?	64/144=44.4%	34/141=24.1%
Sufficiency：预警中多少有该记录?	80/218=36.7%	107/191=56.0%
Sufficiency：没预警中多少有该记录?	64/357=17.9%	34/123=27.6%

两个看似矛盾、其实都正确的结论

Female实际退学记录中更容易被漏掉：FNR较高。Male未预警者中有退学记录的比例较高：FOR较高。

这没有矛盾。第一句从144名和141名实际退学者出发；第二句从357名和123名未预警者出发。它们不是在相同的人群里计算。

如何记住三种标准?

先问“筛选的第一步是什么”：全部人看预警，是Independence；先筛实际结局，是Separation；先筛模型决定，是Sufficiency。

讲结果时先说中文条件，再报分子、分母，最后报百分比。即使忘记缩写，也能让听众知道你比较了谁。

26 | 为什么同一规则仍不保证公平?

主模型没有把Gender直接作为输入，但年龄、专业等变量可能与记录性别有关；现实机会和资料测量也可能有差异。因此“删掉性别”不能自动推出群体结果相同。

基础率Base rate先不同

测试Female组有144/575=25.0%的退学记录；Male组为141/314=44.9%。它们不是模型预测，而是实际记录的比例。

若某组实际正类更多，同样的误报率和识别率也可能产生更高PPV。具体关系可以写成：

PPV = TPR × base / [TPR × base + FPR × (1-base)]

不用背公式。只要理解：预警里有多少真实退学记录，还取决于原来有多少退学记录，不只由模型错误率决定。

三种标准不是三个必拿满分的按钮

在基础率不同、预测不完美等常见条件下，一些公平标准会冲突。不能要求所有指标同时相等而不讨论条件，也不能把“存在取舍”当成忽略明显差异的理由。

即使存在完美预测，Separation与二分类Sufficiency可以满足，Independence仍可能因基础率不同而不满足；因此不能随口背“任何情况三个永远不兼容”。

实际使用应该讨论支持机会、错误代价、标签含义和当事人的权利。本项目是诊断这些问题，不是已经替学校决定哪一种公平标准具有最高优先级。

27 | 为什么要给比例加上不确定性区间?

我们看到的44.4%和24.1%来自有限测试记录。若拿到不同但相似的一批记录，计算结果会变。Bootstrap帮助估计这种变化有多大。

本项目的重复抽样，逐步想象

1. 保持已经训练好的模型、0.31阈值和每条记录的预测不变。

2. 在575名Female测试记录中，有放回抽575条；Male中也有放回抽314条。

3. “有放回”表示某条可能被抽多次，另一些这次没有被抽到。

4. 对抽出的记录重新数四格，计算各组FNR等指标和两组差值。

5. 重复5,000次，保留这些统计量中间95%的范围。

这5,000次不是新招募了5,000批真实学生，也不是获得更多独立信息。它用现有资料模拟统计量的变动。

条件区间Conditional interval是什么意思?

这里把模型和阈值固定住了，所以区间只反映在这套固定规则下重抽测试记录的变化。不包含重新训练或重新选阈值的变化，也没有处理入学届别之间的相关性。

增加bootstrap次数主要让模拟分位数更稳定，不会保证真实置信区间越来越窄。原始样本量、变异和方法都影响区间。

95%也不是“95%的个体落在里面”。 这个区间针对统计量，和年龄等个体值的分布范围不同。

28 | Bootstrap代码、区间和正负方向

下面保留真实代码的关键语句，省略循环外的数组准备。ids是该组记录的行号，不是学生新增编号。

```
draws <- lapply(group_rows, function(ids)
  sample(ids, length(ids), replace = TRUE))
boot[b,,g] <- rates(confusion(
  test$dropout[ids], test$flag[ids]))
gap_boot <- boot[,,"Male"] - boot[,,"Female"]
quantile(x, c(.025, .975), na.rm = TRUE)
```

在实际循环中，先执行ids <- draws[[g]]，再计算该组四格与比例。b是第几次重抽；g是哪一组；replace=TRUE表示有放回。

代码保存的是**Male减Female**。FNR差值为24.1%-44.4%=-20.3个百分点，95%条件区间约-30.7到-9.5个百分点。

主讲从“Female多漏掉多少”出发，改成**Female减Male**，就是+20.3个百分点，区间+9.5到+30.7。反转区间必须同时取负并交换两端，不能只改一个负号。

怎样解释95%置信区间?

在抽样近似和方法适用的条件下，若反复取得类似资料并按同样方法构造区间，长期大约95%的这些区间会覆盖相应真实统计量。这里是bootstrap近似，不是无条件保证。

区间不跨0支持这次分析中有差值，但不能证明差值由性别歧视造成；跨0也不能证明两组相同。多个指标的区间还是逐项的，没有作同时推断校正。

29 | 把第7页的点和横线逐个读出来



五个群体比例及其不确定性区间。原图来自当前R分析输出。

紫色圆点是Female，青绿色三角是Male。横坐标是比例，从0%到100%；同一行比较同一个条件下的两组。

点是实际测试记录算出的比例。横线是固定模型与阈值下的95% percentile bootstrap区间，**不是SD标准差，也不是个体范围。**

右边的n不是每一行都一样。FNR那行分母144和141是实际退学记录人数；PPV那行218和191是收到预警的人数。总组人数不能代替这些n。

先读第三行：圆点约44.4%，三角约24.1%，所以Female实际退学者中漏掉份额更高。再读第二行：Male误报率更高，说明“哪组更差”取决于问哪种错误。

比较差异的不确定性应看差值区间，而不是只凭两个横线是否重叠下结论。差值和bootstrap分布分别放在展示第12、13页。

30 | 校准Calibration和Sufficiency不是一回事

模型给的是连续概率p，预警是把p按0.31切成0和1。**同样分数是否有相似结局**，与**同样预警标签是否有相似结局**是不同检查。



按共同概率区间分组的描述性校准图。原图来自当前R分析输出。

图中每个点来自一个共同分数区间，例如0.2到0.4。横轴是区间内平均预测分数，纵轴是实际退学记录比例。接近对角线，表示这一段平均预测与实际较接近。

真实例子：Female在0.2-0.4这段有272人，平均分数29.6%，实际记录25.4%；Male有142人，平均29.5%，实际35.2%。这些是分箱描述，不是每个精确分数的证明。

点大小表示该格人数。当前图略去n<30的格子以免小组估计过于不稳定；这些格子仍在CSV里，图也没有给区间。因此不能凭图宣布分组校准成立。

总体校准可能掩盖分组差异；连续概率校准也不能直接证明按阈值切分后的二分类Sufficiency。答辩时先说清楚在检查概率p，还是标签R。

31 | 备用分析是在检查什么?

这里的sensitivity analysis叫“敏感性分析”，意思是换一个合理设定，看结论怎样变化。它不同于识别率Sensitivity那个指标。

检查一：模型加入记录性别

两模型使用相同训练记录和0.31阈值。加入Gender后，测试AUC从0.718变成0.725，但Female FNR变为56.9%，Male FNR变为9.2%。一个总体分数稍好，不代表错误分配更合适。

指标	主模型无Gender	额外模型含Gender
Female FNR	44.4%	56.9%
Male FNR	24.1%	9.2%
Female FPR	32.0%	19.5%
Male FPR	48.6%	71.7%

检查二：排除仍在读Enrolled

测试集有160名Enrolled，排除后剩729名Dropout或Graduate。同一个主模型在这批记录的AUC约0.756；另用不含Enrolled的训练记录重拟合后约0.758。

后一个模型在同一数值阈值下识别率约81.8%，但分析人群和问题已经改变。这不能替换原先889人的主分析，也不能当作“调到更高分”的成果。

这两个检查在展示第15、16页。它们展示设定的重要性；主结果仍来自预先固定的模型和验证规则。

32 | R代码从哪里开始读？先读数据处理

打开student-dropout-final.Rproj进入项目。RStudio是操作界面，R是运行代码的语言，Rmd把文字与代码组织在一起，HTML/PDF是读者看到的输出。

```
raw <- read_delim("data/data.csv", delim = ";",
  locale = locale(decimal_mark = "."),
  trim_ws = TRUE, show_col_types = FALSE,
  name_repair = "minimal")
```

这是实际读表语句：相对路径从项目根目录开始；delim=";"说明列由分号分隔；小数点是点。读取后检查行列、标签和编码，避免把文件读成一大列还继续分析。

常见代码	意思与用途
library(dplyr)	加载处理数据的函数
%>%	把上一步结果送给下一步
transmute()	创建并只保留列出的新表结构
mutate()	加列或修改列，保留其他列
filter()	按条件保留行
count(target)	按类别数有多少行
group_by()	告诉后续汇总按哪些组分别做
summarise()	把每组多行压缩为统计量
pivot_longer()	把多个变量列转成适合分面画图的长表

=通常在函数里设置参数或给新列命名；==才是比较是否相等。原始列名含空格时要用反引号，例如 Age at enrollment 。它与字符串双引号不同。

33 | 复杂代码可以分层理解，不必先全背

先看一段课堂风格的真实汇总

```
training %>% group_by(gender) %>%
  summarise(n = n(), dropouts = sum(dropout),
            rate = mean(dropout), .groups = "drop")
```

每组n是人数；因为dropout只含0和1，sum(dropout)数出1有多少，mean(dropout)就是退学记录比例。.groups="drop"明确让汇总后的表解除分组，避免后续操作继续按组执行；单个分组汇总时通常也会自动解除，它不是提高统计质量的技巧。

left_join(..., by="profile_id")按同一个标识把划分结果接回记录。代码还检查完全相同的记录若存在，不会散到不同数据集；实际本文件没有整行重复。

辅助函数不是新算法

confusion()数四格，rates()统一算分母，lapply()对多个阈值或组重复同一工作。!!!as.list(rr)把命名结果展开成表格列，是额外的R实现语法；第一遍先理解它没有改变公式即可。

knitr::kable()只把结果排成表，不改变统计值。echo=FALSE隐藏展示里的代码，但源文件仍保留代码；这和删除分析步骤不同。

文件	负责什么
R/analysis.R	导入、划分、拟合、评价与bootstrap
results/中的CSV	已保存的实际数字、分组和预测
R/refresh_figures.R	读取固定结果更新展示图，不重新选择模型
presentation.Rmd	组织幻灯片，隐藏代码
render_project.R	渲染项目；来源变化时会触发相应更新
verify_project.R	检查数值和信息泄漏边界

想重现时先读README，再在RStudio运行source("render_project.R")和source("verify_project.R")。不要只改PPT里的数字而不更新R结果。

34 | 主展示第1-4页，应该怎样讲?

第1页：问题和用途

核心：入学信息能否识别后来的退学记录，谁更容易被漏掉？用途围绕支持，不预测人的命运。

可用英文： “We ask whether enrolment information can identify later recorded dropout, and who is more likely to be missed.”

衔接：先解释标签，听众才知道“识别到了什么”。对应本讲义第1、4-5节。

第2页：来源、三种标签与观察终点

核心：一所葡萄牙高校、4,424条、正常学制终点。Enrolled保留为无该退学记录，不称为毕业；标签包含转学或换专业。

可用英文： “Enrolled students have no recorded dropout at that endpoint; we do not assume they graduated.”

衔接：定义清楚后，看入学信息是否存在群体模式。对应本讲义第3-6节。

第3页：训练集箱线图

核心：年龄有群体差异，成绩仍有大量重叠。说明只看一个特征无法确定个人结局；n是训练组人数。

可用英文： “The distributions overlap, so these patterns do not determine an individual's outcome.”

网站理由简短讲补充样本量即可，不必介绍整个网站。对应本讲义第8-9节。

第4页：模型、信息时间与三份数据

核心：年龄、成绩、专业；排除后来信息；训练拟合、验证选规则、测试检验。主模型不含Gender。我们把熟悉的课堂汇总和绘图用于探索；对逻辑回归和验证补学后重新编程核对。

可用英文： “We fitted on training records, chose the threshold on validation records, and evaluated the frozen rule on test records.”

衔接：模型有了概率，还要解释为什么选0.31。对应本讲义第10-12节。

35 | 主展示第5-8页，应该怎样讲?

第5页：阈值是我们的选择

核心：验证集至少70%识别率下选最高Specificity，得到0.31。两组共同使用，未在测试上调整。这是分析目标，不是校方规定。

可用英文： “The seventy per cent target is our illustrative choice, not an agreed university policy.”

衔接：接着看独立测试表现，不拿验证目标当保证。对应本讲义第13节。

第6页：Sensitivity提高，Precision下降

核心：主画面明确列出Sensitivity 65.6%=187/285，Precision 45.7%=187/409，Accuracy 64.0%=569/889。比较表保留不预警基准和0.50、0.31两个规则。找到更多也带来更多误报；还有98个退学记录被漏掉。

可用英文： “We found more recorded dropouts, but also produced more false warnings.”

衔接：总体平均数无法告诉我们98个漏报来自谁，因此下一页应用课堂公平标准，检查不同记录性别组的错误率。对应本讲义第14-20节。

第7页：同一规则，不同错误模式

核心：先接住上一页98个漏报，其中64个女性、34个男性；再按实际退学人数作分母：64/144=44.4%、34/141=24.1%。Male FPR更高；五行对应三类公平问题。讲分母，简短解释条件区间。

可用英文： “Among recorded dropouts, female students were missed more often. Male students had the higher false-warning rate.”

不把差别直接叫歧视。对应本讲义第21-29节。

第8页：结论与真实使用前的缺口

核心：有人群预测信号，但需核实标签、资源、群体错误，验证后续学生，保留人工审阅和纠错。

可用英文： “We evaluated a warning rule. We have not shown that acting on it prevents dropout.”

这里的短英文是理解和练习用句，不是把现有597词主讲稿全部替换或额外加进七分钟。

36 | 第9-18页备用页，以及项目真正的限制

展示页	放什么	什么时候翻出来
9	来源与工具辅助说明	解释资料和方法出处
10	三个公平标准的五行表	被问“标准有什么区别”
11	分组四格人数	被问“分母怎么算”
12	Male-Female差值区间	被问“差别有多不确定”
13	FNR差值bootstrap分布	被问“区间怎么做”
14	分组描述性校准	被问“概率可靠吗”
15	加入Gender的比较	被问“不用性别就公平吗”
16	Enrolled定义敏感性	被问“仍在读为何归0”
17	课堂方法和额外方法	被问“哪些是补学的”
18	训练专业构成	被问“群体组成是否不同”

专业构成图显示Female与Male训练记录在专业上的比例不同。例如护理占Female约20.2%，Male约9.4%。这提示有必要调查组成，不证明它造成测试FNR差异，也不能直接宣称Simpson's paradox。

必须守住的限制： 单一历史高校；无个体年份作未来验证；标签含转学；支持需求未被直接测量；仅两种记录性别；简单相加模型；区间未包含重新拟合或届别聚类。

本项目完成预测评估与差异检查，没有证明干预有效。实际应用还需考虑隐私、知情、支持资源、人类审阅、申诉纠错与外部验证。

37 | 答辩练习：先回答问题，再补证据

为什么选这个题?

理解：我们关心入学时可能采取支持行动的场景，同时检查哪些记录更容易漏掉。不要虚构个人调查或校方合作。

English: “We wanted to study an early support setting and examine both overall errors and group differences.”

为什么不用学期成绩提高准确率?

理解：因为预测时点是入学；以后产生的信息不能支持这个时点的判断。若改成学期结束预警，要重新定义任务。

English: “Semester results were not available at our prediction time, so using them would change the question.”

为什么不用更复杂的模型?

理解：主模型少量变量、假设可解释，便于检查时间与错误。没有声称逻辑回归是最好的模型；复杂模型可留未来比较。

English: “We chose a small model we could explain and audit. We have not established that it is the best possible model.”

为什么准确率反而降低?

理解：降低阈值找到更多退学记录，但也增加误报；Accuracy把两种错误按人数合并，不体现所有支持代价。

English: “Lowering the threshold reduced missed records but increased false warnings, so accuracy alone does not capture the trade-off.”

差值区间不跨0，是不是证明歧视?

理解：不是。条件区间反映固定规则下的抽样变化，没有识别差异原因，也没有评估所有公平维度。

English: “It supports an observed difference under our analysis, but it does not identify discrimination as its cause.”

38 | 关上前面的内容，试着回答这些题

先自己说或写答案，再翻下一页。不会没有关系，但应知道需要回看哪一处。

1. 用一句话说出我们的预测时点、观察终点和正类。

2. Enrolled在主分析中记为0，是否等于说它是Graduate?

3. 主模型输入哪三种信息？为什么不用第二学期成绩?

4. 训练、验证、测试各负责什么？0.31由哪一份选择?

5. 在阈值0.31下，分数恰好0.31会怎样？这是教学规则题。

6. TP187、FP222、FN98、TN382，一共有多少测试记录?

7. 187/285与187/409分别是什么？各自分母是谁?

8. 98/285与98/480分别是什么？为什么同一个98有两个比例?

9. Female FNR为什么用64/144，不是64/575?

10. Independence、Separation、Sufficiency分别先按什么条件看?

11. 完整二分类Sufficiency为什么不能只报告PPV?

12. 主讲的Female-Male FNR差为+20.3pp，备用图Male-Female应是多少?

13. Bootstrap重复5,000次，是否等于获得更多独立学生?

14. 测试AUC0.718，是否等于71.8%学生预测正确?

15. 为什么“不用性别”“置信区间跨0”“图接近对角线”都不能单独证明公平?

16. 我们是否已经证明对预警学生给予支持能减少退学?

加一个讲图练习

对展示第7页任选一行，说清楚：横轴是什么、两种点是什么、分母是什么、区间是什么、结论和限制各一句。

这比只背出五个百分比更能检查你是否真正理解。练习不计分，也不替代小组实际排练。

39 | 参考答案，以及小组怎样开始准备

1-4：入学时预测正常学制终点的Dropout记录；Enrolled不等于毕业；主模型为年龄、入学成绩、专业；未来学期信息不符合时点。训练拟合、验证选阈值、测试评估。

5-8：恰好0.31会预警；总数889；187/285是Sensitivity，187/409是PPV；98/285是FNR，98/480是FOR。后者先看没有预警的人。

9-12：FNR先固定实际Dropout，Female为80+64=144人；Independence看全部人，Separation固定Y，Sufficiency固定R；Sufficiency还要看R=0；反方向是-20.3pp，区间约-30.7到-9.5pp。

13-16：bootstrap重用现有资料，没有增加独立样本；AUC是排序指标；这些单项检查都不足以证明全面公平；没有干预实验，不能证明预警能减少退学。

建议的四人准备方式

发言部分	每人需要解释	对应讲义
第1人：展示1-2页	问题、来源、标签与终点	第1-7节
第2人：展示3-4页	看图、时间边界、模型与划分	第8-12节
第3人：展示5-6页	阈值、四格表和两种错误	第13-20节
第4人：展示7-8页	三种公平问题、区间与限制	第21-30、36节

这只是分工建议，不是贡献记录。全体至少会解释四格表和三个公平标准，不能只会自己的两页。

现有主讲稿597词，按每分钟100词估计讲话时间，另留停顿；主要衔接已经包含在稿中，不要再把备选衔接句额外加读。依据所给说明准备约7分钟讲话并预留问答；必须实际计时。先用中文说明白，再练英文，而不是先背一段不理解的话。

40 | 哪些是课堂内容？还要核对什么？

内容	在目前可读课程材料中的状态
数据类型、factor、导入、汇总与连接	Data Types、Importing、Wrangling、Joining等
箱线图、柱图、ggplot、标签和颜色	Visualising data、Types、Effective Data Visualisation
有放回重抽、分位数区间、不确定性	Quantifying uncertainty；现有lab-03
三个公平标准、偏差与解释边界	Algorithmic Bias第16-19页；Misrepresentation
逻辑回归、三份数据划分、AUC、Brier、选阈值	本项目补充；不声称已在已提供slides中教过

可以追溯的来源

UCI 697：Predict Students' Dropout and Academic Success，Realinho等，CC BY 4.0。 https://doi.org/10.24432/C5MC89

原始数据论文：Realinho等，Data 2022, 7, 146。第1页标签范围；第2页机构与年份；第3页变量时点；第4页结局终点；第16页性别编码。 https://doi.org/10.3390/data7110146

R官方glm说明：https://stat.ethz.ch/R-manual/R-devel/library/stats/html/glm.html

公平定义参考：https://fairmlbook.org/classification.html

图表选择参考：https://www.data-to-viz.com/caveat/boxplot.html 区间标注参考：https://www.data-to-viz.com/caveat/error_bar.html

本讲义所有项目数值来自R/analysis.R和results/已保存结果，图来自当前figures/；Python只排版学习材料，没有重新训练或调阈值。各数字的CSV出处另保存在项目的讲义验证记录中。

仍待小组真实完成： 理解与排练、确认成员分工、核对选题可行性批准、仓库与课程账号访问、单独报告及正式提交。所给要求保留HTML展示作为正式格式；PDF便于学习和分享。不要把本讲义当成批准、提交或评分保证。

工具辅助应按课程规定说明。现有展示已保留辅助来源说明；理解与核查仍由小组实际完成。

我们的第一人称学习说明：我们把课堂的处理数据、绘图、重抽原理和公平标准用于项目。对于不熟悉的建模与验证方法，我们借助AI解释和文档学习，再重新编写主要R分析并运行核对。课堂方法与额外实现分开说明；初稿、来源核查和设计中的实际辅助也保留。